Hyperlink Induced Topic Search (HITS)

Ekaterina Tikhoncheva

Seminar "Information Retrieval"

Universität Heidelberg 19.01.2014

Agenda

- Einführung
- 2 Grundidee
- 3 Algorithmus
 - Schritt 1
 - Schritt 2
 - Konvergenz
- 4 Ergebnisse
- **5** Erweiterungen des Algorithmus
- 6 HITS vs PageRank
- Zusammenfassung
 - Modifikationen

Einführung

- HITS ist ein Algorithmus zum Finden und Bestimmen der Rangordnung der zu einer gegebenen Suchanfrage relevanten Seiten im WWW*
- Entwickelt von Jon M. Kleinberg, 1997 IBM Research Report RJ 10076
- Idee: finde angesehene Informationsquellen (engl. authorities) zu der gegebenen Suchanfrage
- Mathematischer Hintergrund: Eigenvektoren der mit dem Web-Graphen verbundenen Matrix

^{*}in einer Hyperlinked-Umgebung

Drei exemplarische Typen von Suchanfragen

- spezielle:
- "Does Netscape support the JDK 1.1 code-signing API?"[6]
- breit angelegte: "Find information about the Java programming language"[6]
 - Suche nach ähnlichen Seiten "Find pages similar to java.sun.com"[6]

Drei exemplarische Typen von Suchanfragen

- spezielle: Problem der Knappheit
 "Does Netscape support the JDK 1.1 code-signing API?"[6]
- breit angelegte: "Find information about the Java programming language"[6]
 - Suche nach ähnlichen Seiten "Find pages similar to java.sun.com"[6]

Drei exemplarische Typen von Suchanfragen

- spezielle: Problem der Knappheit
 "Does Netscape support the JDK 1.1 code-signing API?"[6]
- breit angelegte: Problem der Vielfältigkeit
 "Find information about the Java programming language"[6]
 - Suche nach ähnlichen Seiten "Find pages similar to java.sun.com"[6]

Ranking

- Man möchte die angesehensten Seiten (Authorities) aus der Menge aller zu der Anfrage relevanten Seiten finden
- Mögliche Hindernisse:
 - die meist relevanten Seiten werden nicht unbedingt durch ein textbasiertes Ranking vorgezogen
 - es kann sein, dass die relevanten Seiten die Wörter aus der Suchanfrage gar nicht enthalten

Authorities und Hubs I

Annahme

Die Relevanz zwischen zwei Seiten wurde vom Ersteller des Links zwischen diesen Seiten geprüft

Stimmt im Allgemeinen nicht (z.B. Navigationslinks, Werbung)

Aber unter dieser Annahme reicht es nur die Linkstruktur des WWW zu betrachten, um die Autorität einer Seite im Bezug auf eine andere zu bestimmen

Authorities und Hubs II

Authorities (Autoritätsseiten)

Relevante Seiten, auf die viele weitere relevante Seiten zeigen

Problem: populäre Seiten kommen immer als Authorities vor

Es muss eine Überlappung in den Links, die auf Authorities zeigen, berücksichtigt werden



Hubs

Seiten, die auf viele Authorities zeigen

HITS Algorithmus

Der Algorithmus besteht aus zwei Schritten:

- Konstruiere einen auf die Suchanfrage fokussierten Teilgraphen des WWW
- ② Berechne rekursiv die Authority- und Hubgewichte für alle Knoten im Teilgraphen aus Schritt 1

Teilgraph vom WWW

Wir stellen das ganze Web als gerichteten Graphen G = (V, E) dar. Gesucht wird ein auf der Anfrage basierter Teilgraph des WWW

Sei eine Suchanfrage σ gegeben. Wir bezeichnen mit \mathbf{Q}_{σ} das Ergebnis der textbasierten Suche

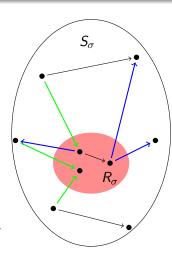
- Q_{σ} ist groß
- ullet Gute Authorities müssen nicht in Q_{σ} liegen

Gesucht wird eine Menge S_{σ} von Seiten, die

- klein ist
- relevante Seiten enthält
- viel gute Authorities enthält

Algorithm 1 Teilgraphen(σ , E, t, d) [6]

- 1: R_{σ} ist die Menge der t besten Ergebnisse des textbasierten Suchalgorithmus E angewendet auf die Anfrage (engl. root set) σ
- 2: $S_{\sigma} := R_{\sigma}$
- 3: **for** p in R_{σ} **do**
- 4: $S_{\sigma} = S_{\sigma} \cup \{Menge \ der \ Seiten, \ auf \ die \ p \ zeigt\}$
- 5: $S_{\sigma} = S_{\sigma} \cup \{Menge\ der\ d\ Seiten,\ die\ auf\ p\ zeigen\}$
- 6: end for



Bemerkungen

Algorithm Teilgraphen (σ, E, t, d) [6]

1: R_{σ} ist die Menge der **t** besten Ergebnisse des textbasierten Suchalgorithmus E angewendet auf die Anfrage (engl.

root set) σ

2: $S_{\sigma} := R_{\sigma}$ 3: **for** p in R_{σ} **do**

4: $S_{\sigma} = S_{\sigma}$

{Menge der Seiten, auf die p zeigt} $S_{\sigma} = S_{\sigma} \cup$

5: $\dot{S}_{\sigma} = S_{\sigma} \cup M$ { Menge der **d** Seiten, die auf p zeigen}

6: end for

In der Implementierung vom Autor [6]:

- t = 200
- d = 50
- $|S_{\sigma}| \sim O(10^3)$
- Lösche Link zwischen den gleichen Domains (Navigationslinks)
- Beschränke Anzahl der Seiten aus einer Domain, die auf die gleiche Seite verweisen (z.B. Werbung)

Berechnen von Authorities und Hubs

Der erste Schritt erlaubt es uns, sich auf die Menge S_{σ} der Seiten zu konzentrieren, die viele angesehene Seiten (Authorities) enthält und gleichzeitig klein genug ist, um die nicht trivialen Algorithmen anwenden zu können

Annahmen

- Ein guter Hub zeigt auf viele gute Authorities
- Eine gute Autorität ist das Ziel von vielen guten Hubs





Sei Graph $G=G[S_\sigma]$ aus dem Schritt 1 gegeben. Wir bezeichnen mit A die Adjazentmatrix des Graphen G

Für jede Seite $p \in V$ werden ein nicht negatives **Autoritätsgewicht** $\mathbf{x}(\mathbf{p})$ und nicht negatives **Hubgewicht** $\mathbf{y}(\mathbf{p})$ definiert, so dass es $\sum_{p \in V(G)} (x(p))^2 = 1$ und $\sum_{p \in V(G)} (y(p))^2 = 1$ gelten

Wir betrachten weiter die Gewichte $\{x(p)|p\in V(G)\}$ und $\{y(p)|p\in V(G)\}$ als n- dimensionale Vektoren x und y (n=|V(G)|), wobei jeder Eintrag dem Gewicht x(p) (y(p)) der Seite p entspricht, $p\in V(G)$

Es werden zwei Operationen definiert:

$$\mathcal{I}(\mathbf{y}) = \sum_{q:(q,p)\in E(G)} y(q) = A^{T} y$$
$$\mathcal{O}(\mathbf{x}) = \sum_{q:(p,q)\in E(G)} x(q) = Ax$$

Algorithm 3 Iteriere (G, k) [6]

- 1: $z=(1,\ldots,1)\in\overline{\mathbb{R}^n}$
- 2: $x_0 := z$ 3: $y_0 := z$
- 4: **for** i = 1, ..., k **do**
- 5: $x_i' := \mathcal{I}(v_{i-1})$
- 6: $v_i' := \mathcal{O}(x_i')$
- 7: normiere $x_i' \to x_i$ $\sum_{p \in V(G)} (x_i(p))^2 = 1$
- normiere $y_i' \rightarrow y_i$ 8: $\sum_{p \in V(G)} (y_i(p))^2 = 1$
- 9: end for
- 10: return (x_k, y_k)

Algorithm 4 Filter(G, k, c)[6]

- 1: $(x_k, y_k) = Iteriere(G, k)$
- 2: Authorities $\{$ Seiten mit c größten Einträgen von $x_k \}$
- 3: Hubs {Seiten mit c größten Einträgen von yk
- 4: return (Authorities, Hubs)

 $x_i, y_i \in \mathbb{R}^n$ bezeichnen Authorityund Hubgewichte nach der i - teIteration des Algorithmus

$$\mathcal{I}(y_i) = \sum_{q:qp \in E(G)} y_i(q)$$

$$\mathcal{O}(x_i) = \sum_{q:pq \in E(G)} x_i(q)$$

Beispiel



<i>x</i> ₀	(1,1,1,1)	<i>y</i> ₀	(1,1,1,1)
<i>x</i> ₁	(0, 0.41, 0.82, 0.41)	<i>y</i> ₁	(0.80, 0, 0.27, 0.53)
<i>x</i> ₂	(0, 0.17, 0.85, 0.51)	<i>y</i> ₂	(0.84, 0, 0.11, 0.53)
<i>X</i> 3	(0, 0.07, 0.85, 0.52)	<i>y</i> ₃	(0.85, 0, 0.04, 0.53)
<i>x</i> ₄	(0, 0.03, 0.85, 0.53)	<i>y</i> ₄	(0.85, 0, 0.02, 0.53)
<i>x</i> ₅	(0, 0.01, 0.85, 0.53)	<i>y</i> ₅	(0.85, 0, 0.01, 0.53)
<i>x</i> ₆	(0, 0, 0.85, 0.53)	<i>y</i> ₆	(0.85, 0, 0, 0.53)
<i>X</i> 7	(0, 0, 0.85, 0.53)	<i>y</i> ₇	(0.85, 0, 0, 0.53)

Konvergenz

Aus dem Algorithmus folgt $y_k = (AA^T)^k z$

Sei $w_1(AA^T)$ der Haupteigenvektor von AA^T , d.h. Vektor zu dem betragsgrößten Eigenwert

Man kann zeigen, dass der Vektor z zu $w_1(AA^T)$ nicht orthogonal ist, und da die Matrix AA^T symmetrisch ist, konvergiert die Folge $\{y_k\}$ gegen $w_1(AA^T)$ (Power Iteration, Potenzmethode [4]). Außerdem hat $w_1(AA^T)$ nur positive Einträge (siehe Peron-Frobenius Theorem)

Analog konvergiert $x_k = (A^T A)^{k-1} A^T z$ gegen $w_1(A^T A)$

In der Praxis lässt man den Algorithmus nicht bis zu Konvergenz laufen, sondern führt eine feste Anzahl k^* von Iterationen durch

^{*}k=20 sei ausreichend [6]

Beispiel (Fortsetzung)

$$A = \begin{pmatrix} 0 & 0 & 1 & 1 \\ 0 & 0 & 0 & 0 \\ 0 & 1 & 0 & 0 \\ 0 & 0 & 1 & 0 \end{pmatrix}$$

$$A^T A = \begin{pmatrix} 0 & 0 & 0 & 0 \\ 0 & 1 & 0 & 0 \\ 0 & 0 & 2 & 1 \\ 0 & 0 & 1 & 1 \end{pmatrix}$$

$$AA^T = \begin{pmatrix} 2 & 0 & 0 & 1 \\ 0 & 0 & 0 & 0 \\ 0 & 0 & 1 & 0 \\ 1 & 0 & 0 & 1 \end{pmatrix}$$

$$\begin{array}{lll} \text{Eigenwerte} & \text{Eigenvektoren} \\ \lambda_1 = 0 & (1,0,0,0) \\ \lambda_1 = 0.38 & (0,0,-0.53,0.85) \\ \lambda_1 = 1 & (0,1,0,0) \\ \lambda_1 = 2.62 & (0,0,0.85,0.53) \end{array}$$

$$\begin{array}{ll} \text{Eigenwerte} & \text{Eigenvektoren} \\ \lambda_1 = 0 & (0,1,0,0) \\ \lambda_1 = 0.38 & (-0.53,0,0,0.85) \\ \lambda_1 = 1 & (0,0,1,0) \\ \lambda_1 = 2.62 & (0.85,0,0,0.53) \end{array}$$

Somit sehen wir, dass die Folgen $\{x_k\}$ und $\{y_k\}$ konvergieren entsprechend gegen $w_1(A^TA)$ und $w_1(AA^T)$.

Ergebnisse: Suchanfrage "Gates" I

HITS [6]

(Gates) Authorities .643 http://www.roadahead.com/ .458 http://www.microsoft.com/ .440 http://www.microsoft.com/corpinfo/bill-g.htm

Bill Gates: The Road Ahead Welcome to Microsoft

www.ask.com

http://www.ask.com/wiki/Bill_Gates?lang=en www.gates.com/

www.gates.com/all-search-tools/automotive-interchange-search-results us military. about.com/od/glossary terms g/g/g2641.htm

www.gatesfoundation.org/

Gates Corporation (manufacture)

gate
Bill & Melinda Gates Foundation

Ergebnisse: Suchanfrage "Gates" II

www.google.com

www.gates.com/ Gates Corporation ww2.gates.com/germany/ Gates Corporation de.wikipedia.org/wiki/Bill_Gates

http://www.gatesbbg.com

Gates Bar B. Q. http://www.gatesfoundation.org Gates Foundation

www.search.yahoo.com

www.gates.com/ www.gateschevvworld.com www.gatecrafters.com/design_your_gates.aspx www.gates.com/industries/automotive http://www.gatesbbq.com

Gates Corporation Gates Chevy World - Mishawaka, Elkhart, South Bend Driveway Gates | Automatic Gates | Electric Gates Gates Automotive Aftermarket Solutions | Gates Corporation Gates Bar B. Q.

Ergebnisse: Suchanfrage "Java" I

HITS [6]

(java) Authorities Gamelan (Sara) Gamelan (Sara) Gamelan (Sara) Hurne Page JavaSoft Hurne Page JavaSoft Hurne Page 190 http://www.digitalfocus.com/digitalfocus/faq/howdoi.html The Java Book Pages (Java Book Pages List) http://smistic.unc.edu/-srp/java/javahooks.html The Java Book Pages (Java Book Pages Pages List) http://smistic.unc.edu/javafaq/javafaqhulml comp.lomg.java FAQ

www.ask.com

www.ehow.com What is Java?
www.ask.com/wiki/Java_(programming_language)?lang=en Wiki
java.com/download java
java.about.com/ ORACLE

ORACLE

Ergebnisse: Suchanfrage "Java" II

www.google.com

www.java.com/de/download/ Download der kostenlosen, Java-Software

www.java.com/de/ java.com: Java + Sie Download Free Java Software www.java.com/download

www.iava.com/en/ iava.com: Java + You

de.wikipedia.org/wiki/Java (Programmiersprache)

www.search.yahoo.com

www.java.com iava.com/en/download www.oracle.com/technetwork/es/java/javase/overview/index.html windows.microsoft.com/en-US/internet-explorer/install-java

Java SE - Downloads Install Java in Internet Explorer www.java.net java.net - Official Site

Java - Official Site Download Java

Bewertung der Ergebnisse

In seiner Arbeit [6] gibt Kleinberg folgende Evaluationsergebnisse an:

Es wurden die Suchergebnisse von Yahoo!, CLEVER*[2] und AltaVista[1] verglichen, indem 37 Freiwillige die Qualität der von verschiedenen Suchmaschinen vorgeschlagenen Seiten zu den fest gewählten Themen abschätzen sollten

Die Ergebnisse sind:

In 50% der Fälle: CLEVER war besser.

In 31% der Fälle: Yahoo! und CLEVER waren gleich gut.

In 19% der Fälle: Yahoo! war besser.

^{*}Implementation von HITS mit Erweiterungen

Suche nach ähnlichen Seiten

- Die Suchanfrage σ sei eine Internetseite $R_{\sigma} = \{ \text{Menge der Seiten, die auf } \sigma \text{ zeigen} \}$
- Wende den HITS Algorithmus an

```
(www.honda.com) Authorities
.202 http://www.toyota.com/
                                            Welcome to @Toyota
.199 http://www.honda.com/
                                            Honda
.192 http://www.ford.com/
                                            Ford Motor Company
.173 http://www.bmwusa.com/
                                            BMW of North America, Inc.
.162 http://www.volvocars.com/
                                            VOLVO
.158 http://www.saturncars.com/
                                            Welcome to the Saturn Web Site
.155 http://www.nissanmotors.com/
                                            NISSAN - ENJOY THE RIDE
.145 http://www.audi.com/
                                            Audi Homepage
.139 http://www.4adodge.com/
                                            1997 Dodge Site
.136 http://www.chryslercars.com/
                                            Welcome to Chrysler
```

Mehrere Mengen von Hubs und Authorities

- Der betrachtete Algorithmus liefert die am dichtesten vernetzte Menge der Authorities und Hubs im auf der Suchanfrage basierten Teilgraphen des WWWs
- Es gibt eventuell weitere dicht vernetzte Mengen, die zu der Anfrage relevant sind (z.B. mehrdeutige Anfrage)
- betrachte weitere Eigenvektoren, sortiert nach Betragsgrößen
- betrachte positive und negative Teile eines Nicht-Haupteigenvektors

HITS

- wird auf einem Teilgraphen des WWW angewendet
- einfacher, aber langsam in Echtzeit
- berechnet Autoritätsseiten und Hubs
- beruht auf textbasierter
 Suche
- kann "diffundieren"

PageRank

- benutzt ganzen Graphen des WWW
- dauert lange, wird aber nur einmal beim Indexieren berechnet
- berechnet nur Autoritätsseiten
- unabhängig vom Kontext

Zusammenfassung: I

- Wegen der hohen Anzahl von Webseiten ist bei der Internetsuche ein Ranking-Verfahren sehr nützlich
- Als Ergebnis der Suche werden t Autoritätsseiten zurückgeliefert
- Jeder Link enthält einen gewissen Anteil der Autorität des Erstellers des Links
- Autoritätsseiten sind zu der Anfrage relevante Seiten mit vielen eingehenden Links
- Hubs sind Seiten, die auf viele Autoritätsseiten verlinken
- Der ganze WWW-Graph ist zu groß ⇒ betrachte auf der Anfrage basierten Teilgraphen

Zusammenfassung: II

- HITS-Algorithmus
 - arbeitet auf dem generierten Teilgraphen
 - ist ein rekursiver Algorithmus
 - konvergiert gegen Haupteigenvektoren der Matrizen A^TA und AA^T, wobei A die Adjazentmatrix des betrachteten Teilgraphen ist
 - liefert Seiten zurück, die den c größten Einträgen des Haupteigenvektors der Matrix A^TA entsprechen
 - kann für die Suche nach ähnlichen Seiten benutzt werden
 - kann die für verschiedene Bedeutungen der Anfrage relevanten Seiten liefern
- HITS wurde in der Suchmaschine CLEVER (IBM Project) implementiert (nicht mehr in Betrieb)
- HITS wird in der Suchmaschine Ask.com benutzt ([10])

Modifikationen

Problem :

Topic Drift
Ergebnisse bei bestimmten Strukturen des Webs sind nicht intuitiv klar [8]

- Modifikationen des Algorithmus
 - Gewichteter HITS-Algorithmus ([3, 7, 8])
 - HITS-Algorithmus mit potenzierter Eingabe ([8])

Modifikationen

The End

Vielen Dank für Ihre Aufmerksamkeit!

Modifikationen



References I

- [1] Altavista. www.de.wikipedia.org/wiki/AltaVista. Accessed: 2015-15-01.
- [2] CLEVER project. www.en.wikipedia.org/wiki/CLEVER_project. Accessed: 2015-15-01.
- [3] Krishna Bharat and M. R. Henzinger. Improved Algorithms for Topic Distillation in a Hyperlinked Environment. Proceedings of the 21st ACM SIGIR Conference on Research and Development in Information Retrieval, 1998.
- [4] G.H. Golub and C.F. Van Loan. *Matrix Computations*. Johns Hopkins University Press, 1996.

References II

- [5] Joni Pajarinen. The pagerank/hits algorithms. www.cis. hut.fi/Opinnot/T-61.6020/2008/pagerank_hits.pdf. Accessed: 2015-15-01.
- [6] John M. Kleinberg. Authoritative sources in a hyperlinked environment. In Proc. 9th ACM-SIAM Symposium on Discrete Algorithms, 1998.
- [7] Yi Shang Li, Longzhuang and Wei Zhang. Improvement of HITS-based algorithms on web documents. *Proceedings of the 11th international conference on World Wide Web. ACM*, 2002.

References III

- [8] J. C Miller, G. Rae, and F. Schaefer. Modifications of Kleinberg's HITS Algorithm Using Matrix Exponentiation and Web Log Records. Proceedings of the 24th annual international ACM SIGIR conference on Research and development in information retrieva, pages 444–445, 2001.
- [9] Jannik Strötgen. Beamer theme. http://dbs.ifi.uni-heidelberg.de/fileadmin/Team/ jannik/beamerthemeHeidelberg.sty. Accessed: 2015-15-01.

References IV

- [10] Raluca Tanase and Remus Radu. The mathematics of web search, lecture 4: Hits algorithm - hubs and authorities on the internet. www.math.cornell.edu/~mec/Winter2009/ RalucaRemus/Lecture4/lecture4.html. Accessed: 2015-15-01.
- [11] Zhe Zhao. Authoritative sources in a hyperlinked environment, Jon M. Kleinberg. web.eecs.umich.edu/~michjc/eecs584/notes/lecture19-kleinberg.pdf. Accessed: 2015-15-01.